# WHO 平均餘命：多元線性回歸分析

CRISP-DM 作業報告｜資料與程式執行日期：2026-11-01｜姓名：李易軒｜學號：5115056026

## 摘要

以國家年度健康與社經指標估計平均餘命。原始檔有 2,938 筆；排除 10 筆缺少目標後，依國家切分訓練與保留資料。以訓練國家的五折交叉驗證選擇 OLS 主模型；20 特徵 OLS 的保留集 MAE 為 3.121 年、RMSE 為 4.063 年，$R^2$ 為 0.823。資料中的同年度死亡率等欄位可能與目標存在概念重疊，本研究不能解讀為因果效果或未來預測。

## 1. Business Understanding｜問題理解

研究問題：能否利用國家年度的健康與社經資訊估計未見國家的平均餘命？成功標準為優於訓練資料平均值基準，並檢查誤差、特徵選擇與線性模型限制。此資料為國家層級觀測，不能推論個人壽命。

## 2. Data Understanding｜資料理解

資料來源：Kaggle「Life Expectancy (WHO)」：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who 。本機 CSV 包含 193 國、2000–2015 年、22 欄；國家及年份組合沒有重複。目標為 Life expectancy；20 個輸入包含 Year、Status 與 18 個健康、人口及社經數值指標。原始 CSV 的 SHA-256：872125dd1dd0f9140fbead61df20585a815f5cf47db68f08bf54efaf87963b11。

缺失較多的欄位包括 Population（652）、Hepatitis B（553）及 GDP（448）；目標缺失 10 筆直接排除。資料來源描述、版本與再散布條件須於提交前核對。

## 3. Data Preparation | 資料準備

國家名稱不進模型，只作分組依據。Status 以 Developing=0、Developed=1 編碼。保留 37 個國家共 592 筆，其餘 146 個國家共 2,336 筆訓練；資料分組以 seed 42 固定。訓練集內使用五折 GroupKFold，同一國家不會跨訓練折與驗證折。中位數補值與標準化放入 pipeline，由各折訓練資料擬合。此切分評估跨國泛化，並不驗證對未來年份的預測。

## 4. Modeling | 建模

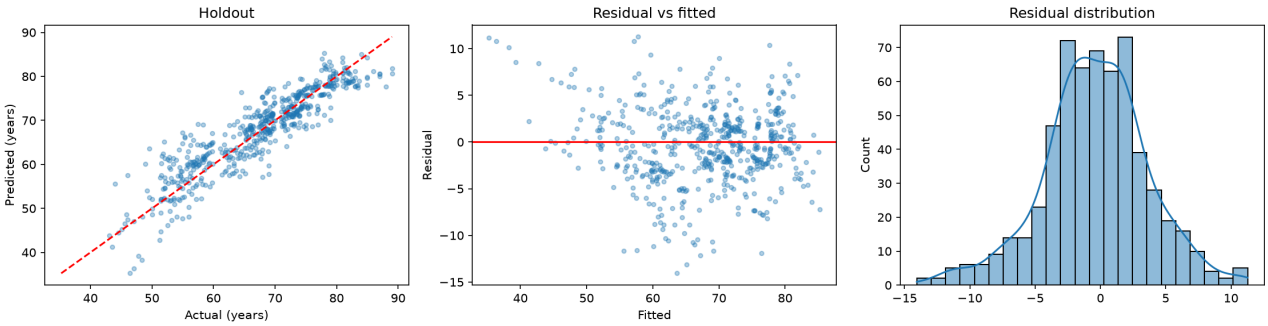
候選包括平均值基準、20 特徵 OLS、SelectKBest 與 RFE 各選 14 特徵，以及 Ridge、Lasso；正則化強度以相同分組交叉驗證比較。以訓練 CV RMSE 選 OLS 主模型，結果為全部 20 特徵；CV 選參後的最佳分數可能樂觀，保留集用作最終評估。

| 模型 | CV RMSE | 保留集 MAE | 保留集 RMSE | 保留集 $R^2$ |
|---|---|---|---|---|
| dummy | 9.434 | 7.982 | 9.949 | -0.059 |
| ols | 4.337 | 3.121 | 4.063 | 0.823 |
| kbest | 4.635 | 3.122 | 4.122 | 0.818 |
| rfe | 4.338 | 3.121 | 4.063 | 0.823 |
| ridge_1 | 4.270 | 3.116 | 4.059 | 0.824 |
| lasso_0.01 | 4.284 | 3.110 | 4.057 | 0.824 |

OLS、RFE 的 CV RMSE 幾乎相同，兩者的差距不應被解讀為明確的實務優勢。選取清單儲存在 outputs/selected_features.json；Lasso 最終保留 19 個非零係數，屬補充比較。

## 5. Evaluation | 評估

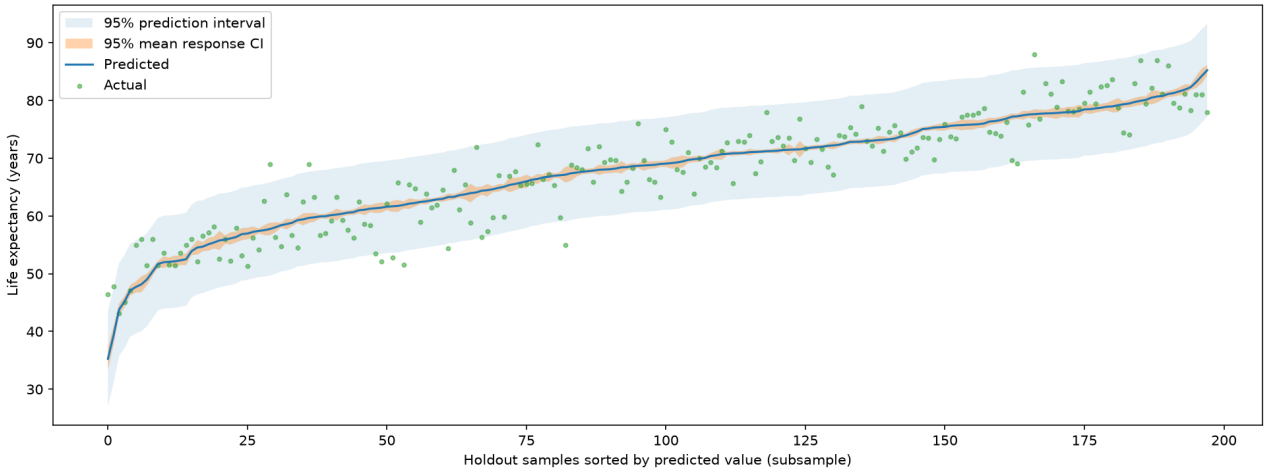
保留集的 OLS 調整後 $R^2$ 為 0.817；平均值基準 RMSE 為 9.949 年。實際值與預測值及殘差圖如下。不同國家、年度的資料量不一，這些指標按資料列計算，不是每國等權的平均誤差。



## 回歸診斷與區間

訓練資料 Breusch－Pagan LM 檢定 p 值約
3.88e-58，提示殘差變異可能不一致；同國觀測相依使傳統檢定的推論受到限制。infant deaths 與 under-five deaths 的 VIF 約為 189 與 188，顯示嚴重共線性。殘差圖與 Q-Q
圖可協助判斷線性及常態偏離；同國跨年度相依性不能從任意排序的 Durbin－Watson 判定。

以下是依預測值排序的部分保留樣本，帶狀區分 95% 平均反應信賴區間與單筆觀測預測區間。區間依傳統 OLS 假設計算，未納入模型選擇的不確定性；異質變異與國家內相關可能使覆蓋率偏離 95%。




## 6. Deployment｜部署

完整前處理與選定的 OLS 已存為 joblib；Notebook 驗證重載前後預測一致。可使用 hw2lib.predict 接收新 CSV，檢查必要欄位、數值與 Status
類別，再輸出預測。此研究模型不應直接用於政策或個人判斷。

## 限制與後續

這是觀察性、國家層級、歷史資料；不可宣稱因果。資料可能存在指標定義變更、缺失機制不隨機、估計值誤差及同國年度相依。部分死亡率與平均餘命在概念或推估流程可能重疊，需確認發布時間與來源後才能主張事前預測。OLS 係數受嚴重共線性影響，係數方向及大小不能直接解讀為政策效果。

## GPT 輔助內容

本作業使用 GPT／Codex
協助整理多元線性回歸的分析流程、檢查程式與模型評估方法、解讀圖表及研究限制，並協助組織 CRISP-DM 報告與網站的說明文字。資料集選擇、研究問題及最終呈現由我確認；報告中的樣本數、特徵選擇結果、MAE、RMSE、$R^2$ 與預測區間，均以實際執行 Notebook 或分析程式所產生的結果核對。針對 AI 提出的解釋，我也檢查程式與資料來源，沒有將 AI 回答直接當作實驗結果或研究文獻。

## NotebookLM 摘要

我使用 NotebookLM 研究 Furkan Kazan 在 Kaggle 發表的 WHO 平均餘命線性回歸 Notebook，並與本作業比較。兩者都使用 WHO 平均餘命資料建立線性回歸模型，但處理缺值與評估模型的方式不同。Kaggle Notebook 刪除部分有缺值的資料列，以中位數補入 GDP 的缺值，並採用隨機資料列切分；本作業的平均餘命分析只刪除缺少預測目標的 10 筆紀錄，其餘特徵在訓練流程中補值，並依國家分組，以未參與訓練的國家進行評估。本作業也比較完整模型與兩種特徵選擇方法。

比較時，我發現 Kaggle Notebook 的線性模型在切分測試集之前，已使用全部資料訓練，因此其後顯示的線性回歸 $R^2$ 不能視為獨立測試結果。兩份研究雖然都報告 $R^2$，仍不能直接以數值高低判斷模型優劣；若要公平比較，必須使用相同的資料處理、特徵及測試方式。這次研究讓我了解，解讀模型結果時，評估流程與分數同樣重要。

研究來源：Furkan Kazan，Life_Expectancy_LinearRegression，版本 6，程式第 19–22、48–52 格。Kaggle Notebook 原文 ↗。NotebookLM 的使用描述與摘要依作業者提供之紀錄整理；對話紀錄另存 PDF。

# HW2 GPT／Codex 對話紀錄

姓名：李易軒 學號：5115056026

本檔擷取本次 Codex 對話截至匯出時間可取得的使用者訊息與助理回覆及進度；工具執行細節及原始圖片未收錄。

## 01｜使用者

## My request:
請你按照 2026-10-19-hw2-regression-design 的規則
以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析
並遵循 CRISP-DM 流程完成從資料理解、建模到評估，以 vscode 開始實作做作業

***以下是我要用在做作業的 Kaggle 資料集
https://www.kaggle.com/competitions/predictheflood
https://www.kaggle.com/datasets/mssmartypants/paris-housing-price-prediction
https://www.kaggle.com/datasets/larsen0966/student-performance-data-set

***以下是教授給的作業規範，請你一同按照這個標準實作
https://app.notion.com/p/AIoT-L7-HW-2-Multiple-Linear-Regression-3f9c47529811809caba6d4116dcc5f6d

## 02｜Codex｜進度

我會先確認作業設計規則、教授的評分要求與資料集內容，再依 CRISP-DM 建立可在 VS Code 執行的完整分析。

## 03｜Codex｜進度

我會依現有的作業設計文件作為實作依據，並使用 brainstorming 的需求檢核流程確認資料與規範是否一致。

## 04｜Codex｜進度

設計文件預設採用洪水資料集，以 20 個原始特徵及兩種 14 特徵選擇法比較；我會依此開始。教授的 Notion 頁面目前無法透過連接工具讀取，因此先依設計文件中已記錄的評分要求執行，同時確認資料取得方式。

## 05｜Codex｜進度

我會使用 writing-plans 將設計拆成可驗證的實作步驟；目前專案尚無資料檔，Windows 的 Python 啟動器也未偵測到已安裝版本，正在確認可用環境。

## 06｜Codex｜進度

實作計畫已建立。資料分析需要的套件尚未安裝，且目前資料夾內沒有原始 CSV；我會先嘗試建立專案專用環境並取得指定競賽資料。

## 07｜Codex｜進度

環境建立時遇到暫存資料夾的存取限制；我已確認錯誤發生在安裝工具初始化，正在處理環境權限。

## 08｜Codex｜回覆

請將指定洪水競賽下載的訓練 CSV 放入專案的 data/raw 資料夾，並告訴我檔名；競賽資料可能需要您的 Kaggle 帳號接受規則才能下載。

## 09｜Codex｜進度

專案專用環境已建立，分析套件正在安裝。我也已請您協助放入競賽訓練資料；在取得資料前，會先完成可重用的資料驗證與建模準備，不會虛構實驗結果。

## 10｜Codex｜進度

目前已準備好資料驗證的測試與作業說明；套件仍在安裝。取得 CSV 後才能核對 20 個特徵、計算雜湊並進行真正的模型評估。

## 11｜Codex｜進度

資料驗證的第一批測試已通過，包含排除 ID／目標欄位、檢查特徵數及訓練與保留測試集不重疊。接下來會建立交叉驗證模型，確保補值、標準化與特徵選擇都只使用各訓練折的資料。

## 12｜Codex｜進度

環境套件已安裝，依賴檢查沒有發現衝突；目前四項基礎測試通過。我會補上可在 VS Code 開啟的分析起點，並保留未完成項目的明確標記。

## 13｜Codex｜回覆

已依設計文件開始實作，建立了可在 VS Code 開啟的 [分析 Notebook](C:/Users/User/中興課程/01_物聯網/week7/hw_2/hw2_regression.ipynb)，並以設計文件預設的 **Predict the Flood** 作為研究主題。

目前已完成專案專用 Python 環境、資料欄位驗證，以及 OLS、兩種特徵選擇法、Ridge 和 Lasso 的模型準備。四項基礎測試通過，套件依賴檢查也未發現衝突。操作方式與目前進度記錄在 [README](C:/Users/User/中興課程/01_物聯網/week7/hw_2/README.md)。

**完整分析尚未完成**：專案中目前沒有實際訓練 CSV，因此還沒有執行模型比較、產生評估結果、診斷圖或 PDF 報告。教授的 Notion 頁面這次也無法透過連接工具讀取，目前暫依既有設計文件記錄的要求實作。

請將 [Predict the Flood 訓練資料](https://www.kaggle.com/competitions/predictheflood)下載後，放到 `data/raw/train.csv`，再告訴我已放入；我才能核對來源與欄位，繼續完成實際分析。最終繳交前還需要您的學號、真實的 NotebookLM 紀錄與對話匯出。

## 14｜使用者

## My request:
###我不用這個資料集
https://www.kaggle.com/competitions/predictheflood

###改用以下的資料集
https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who

###你可以參考我在 dataset 放的資料，裡面是我作業要用到的所有資料集的資料

## 15｜Codex｜進度

我會改用 WHO 平均餘命資料，先檢查您放在 `dataset` 的檔案、欄位與資料來源，再調整既有分析設計與程式。

## 16｜Codex｜進度

我會沿用 brainstorming 的需求檢核，並針對這份跨國、跨年度資料調整切分方式，避免同一國家的資料同時進入訓練與測試而高估表現。

## 17｜Codex｜進度

已確認您提供的資料有 2,938 筆、193 個國家、2000–2015 年的紀錄，且目標欄位有 10 筆缺值。同一國家有多個年度，因此本研究將以「預測未見過的國家」為評估目標，按國家分組切分；結果不代表未來年份預測能力。

## 18｜Codex｜進度

資料已改為以 20 個輸入欄位建模，其中 `Status` 轉為二元數值；國家名稱僅用於分組，不作特徵。交叉驗證也會依國家分組，並比較完整 OLS、兩種 14 特徵方法與正則化模型。

## 19｜Codex｜進度

資料切分與模型流程已改好，正在從全新 Notebook 執行實際資料。這一步會完成分組交叉驗證、保留集評估與區間診斷；結果會以實際執行輸出為準。

## 20｜Codex｜進度

實際資料已成功跑完：以國家分組的五折驗證選出 20 特徵 OLS；在未見國家的保留集上，RMSE 約 4.06 年、$R^2$ 約 0.823。接下來會整理特徵選擇、診斷解讀與可重跑說明。

## 21｜Codex｜進度

我會使用 PDF 工作流程整理分析報告，並核對圖表與 Notebook 的實際結果。另已加入新資料預測程式；它會檢查必要欄位與 `Status` 類別。

## 22｜Codex｜進度

結果顯示 OLS 與 RFE 表現非常接近，但兩個死亡人數欄位的共線性很高；Breusch–Pagan 檢定也顯示變異可能不一致。報告會把這些限制寫清楚，避免把係數解讀成因果效果。

## 23｜Codex｜回覆

已改用您放在 `dataset` 資料夾中的 **Life Expectancy (WHO)** 資料，完成實際建模與 CRISP-DM 分析。Notebook 已從頭執行，並保存結果與圖表。

- [開啟分析 Notebook](C:/Users/User/中興課程/01_物聯網/week7/hw_2/hw2_regression.ipynb)
- [查看 VS Code 執行說明](C:/Users/User/中興課程/01_物聯網/week7/hw_2/README.md)
- [查看模型評估表](C:/Users/User/中興課程/01_物聯網/week7/hw_2/outputs/metrics.csv)

PDF 報告草稿：

:codex-file-citation{path="C:/Users/User/中興課程/01_物聯網/week7/hw_2/reports/life_expectancy_report.pdf" purpose="output"}

資料共有 2,938 筆，排除 10 筆缺少目標值的紀錄後，依**國家**切分訓練與測試資料，避免同一國家的不同年度同時出現在兩邊。交叉驗證選出的 20 特徵 OLS，在保留測試集的 **MAE 為 3.121 年、RMSE 為 4.063 年、$R^2$ 為 0.823**。六項程式測試通過，新資料預測流程也已驗證。

分析發現兩個死亡人數欄位有嚴重共線性，且資料可能有異質變異與國家內年度相關，因此係數和傳統預測區間須謹慎解讀；這項研究也不能作為因果結論或未來年份預測的證明。

報告目前仍是**繳交草稿**：需要補上學號、真實的 GPT 對話 PDF、實際 NotebookLM 紀錄與至少 100 字摘要，並核對教授最新規範及資料授權後才能打包。

## 24｜使用者

## My request:
補上
我的名字: 李易軒
我的學號: 5115056026
然後在 local 呈現給我檢查目前畫面

## 25｜Codex｜進度

我會把姓名與學號補進 Notebook 和報告，更新後在本機開啟報告讓您檢查畫面。

## 26｜Codex｜進度

我會使用 PDF 檢視流程確認姓名與學號的排版，再開啟本機畫面供您查看。

## 27｜Codex｜回覆

已將**李易軒／5115056026**補入 Notebook、報告及專案說明，並在本機開啟 PDF 報告供您檢查。

報告首頁預覽：

![報告首頁預覽](C:/Users/User/中興課程/01_物聯網/week7/hw_2/reports/identity-check-1.png)

:codex-file-citation{path="C:/Users/User/中興課程/01_物聯網
/week7/hw_2/reports/life_expectancy_report.pdf" purpose="output"}

[分析 Notebook](C:/Users/User/中興課程/01_物聯網/week7/hw_2/hw2_regression.ipynb)

本機瀏覽器已開啟報告，但電腦操作工具無法確定目前瀏覽器網址，因此停止了最後的畫面確認。報告仍是草稿，尚待補上真實的對話匯出與 NotebookLM 紀錄。

## 28｜使用者

# Context from my IDE setup:

## Active file: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## Open tabs:
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
這個作業是要推上 web 的
請你製作前後端，要有 env 的概念
做好後在 local 呈現給我檢查目前畫面

## 29 | Codex | 進度

我會把目前的平均餘命分析整理成可在本機檢查的前後端網站，包含環境設定與模型預測介面。先確認現有程式與網站實作方式，再啟動本機預覽。

## 30 | Codex | 進度

我會使用 Sites 的本機預覽流程，沿用已訓練的 Python 模型製作後端；網站會呈現研究結果、CRISP-DM 流程與可互動的預測表單。`.env` 會管理埠號與模型路徑等設定。

## 31 | Codex | 進度

後端已接上既有模型，並完成輸入驗證；目前正在製作研究儀表板與預測表單。網站會清楚標示這是歷史資料的跨國研究，避免把結果誤認為個人壽命或未來預測。

## 32 | Codex | 進度

網站首頁已可在本機回應；測試互動時發現範例資料的格式需要調整，我正在修正，完成後會實際送出預測確認前後端連通。

## 33 | Codex | 進度

首頁與預測 API 已通過本機連線測試，範例資料算出的結果約為 59.9 歲。我現在開啟網站供您檢查，並確認畫面呈現。

## 34 | Codex | 回覆

前後端網站已完成，並已在本機開啟供您檢查：

**[開啟 LifeScope 本機預覽](http://127.0.0.1:8000)**

網站包含研究總覽、CRISP-DM 流程、模型結果與可操作的預測表單。表單已連接既有 Python 模型；使用範例資料測試時，畫面成功顯示 **59.9 歲**。目前 10 項測試通過。

環境設定範例在 [.env.example](C:/Users/User/中興課程/01_物聯網/week7/hw_2/.env.example)，啟動與重建方式記錄在 [README](C:/Users/User/中興課程/01_物聯網/week7/hw_2/README.md)。

目前是**本機預覽**，尚未發布到公開網路；本機服務需保持執行，網址才能使用。

## 35 | 使用者

# Context from my IDE setup:

## Active file: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## Open tabs:
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
###我的作業還包括要呈現以下的資料集，但我在 local 並沒有看到這些資料集，請你補上
https://www.kaggle.com/datasets/mssmartypants/paris-housing-price-prediction
https://www.kaggle.com/datasets/larsen0966/student-performance-data-set

###我想要你設計的是有分頁的概念，讓我可以點選一個分頁，就呈現一個資料集的數據
每個前端的文案、提示、input 框、按鈕等也要依照資料集的欄位跟選項去調整

切換分頁後，呈現各自資料集的前端資訊

## 36｜Codex｜進度

我會先核對三份本機資料的實際欄位與內容，再把網站改成可切換的資料集分頁，讓每個分頁顯示對應的說明、欄位與操作。

## 37｜Codex｜進度

我發現「Student Performance Data Set」資料夾內的檔案其實與巴黎房價 CSV 完全相同，並不是學生成績資料。我會先完成巴黎房價分頁，同時確認能否取得您指定的學生成績資料，避免把房價資料誤標為成績。

## 38｜Codex｜回覆

目前 Student Performance 資料夾放的是重複的 ParisHousing.csv。若您已下載正確的學生成績 CSV，請放入該資料夾並告訴我；我也會先嘗試從您提供的 Kaggle 來源取得。

## 39｜Codex｜進度

已從您指定的 Kaggle 資料集取得學生成績檔案，內容是 649 筆葡萄牙語課程資料。接下來會為房價與成績各自建立模型及評估，再讓分頁使用各自的欄位與選項。

## 40｜Codex｜進度

三個分頁將各自使用獨立的資料與模型：房價使用 16 個欄位，學生成績使用 20 個欄位。學生成績模型含第一、二期成績，因此會標明它適合在已有期中成績時使用。

## 41｜使用者

<send_user_message_question_reply>
[{"questionItemId":"[\"request_user_input_async\",\"call_b8fdaf66e2684c0bb9f732447c0febe2\",0]","question":"目前 Student Performance 資料夾放的是重複的 ParisHousing.csv。若您已下載正確的學生成績 CSV，請放入該資料夾並告訴我；我也會先嘗試從您提供的 Kaggle 來源取得。","answer":"請你直接參考我在 C:\\Users\\User\\中興課程\\01_物聯網\\week7\\hw_2\\dataset 放的資料集資料，裡面有我要放在作業的資料集"}]
</send_user_message_question_reply>

## 42｜Codex｜進度

我會以‘dataset‘ 資料夾內的檔案作為網站資料來源。學生成績資料夾原先只有重複的房價檔；我已從您指定的 Kaggle 連結下載正確的‘student-por.csv‘ 放入同一資料夾，房價檔沒有刪除或改動。

## 43｜Codex｜進度

分頁畫面已完成，測試時發現瀏覽器仍連到上一版的本機服務；我正在切換到新版服務並逐一測試各分頁的預測。

## 44｜Codex｜進度

房價與學生成績分頁都已能載入並用各自模型計算。學生資料中的類別與等級欄位也已改成對應選項；我正在做最後的分頁切換與畫面檢查。

## 45 | Codex | 回覆

已完成三個資料集的切換分頁，並在本機開啟供您檢查：

**[開啟本機網站](http://127.0.0.1:8000)**

每個分頁都有自己的資料摘要、模型結果、輸入欄位、選項與預測按鈕：

- **平均餘命**：使用既有 WHO 模型。
- **巴黎房價**：使用您放在 `dataset` 的房價資料，建立獨立模型。
- **學生成績**：使用您指定的 Kaggle 資料集中的葡萄牙語課程資料，建立獨立模型。

原本學生成績資料夾裡是重複的房價檔；我已將正確的 [student-por.csv](C:/Users/User/中興課程/01_物聯網/week7/hw_2/dataset/Student%20Performance%20Data%20Set/student-por.csv) 放入該資料夾，沒有刪除原有檔案。三個分頁的切換與新模型預測已測試，12 項程式測試通過。

目前巴黎房價與學生成績是網站用的**基礎模型分析**；完整 CRISP-DM 報告仍以平均餘命研究為主。網站目前仍為本機預覽，尚未公開部署。

## 46 | 使用者

# Context from my IDE setup:

## Active file: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## Open tabs:
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
請你依照在平均餘命的報告，把巴黎房價跟學生成績的實作報告，經過計算統計，把結果報告也加上前端的閱讀完整報告
並且在各自的分頁上明確標示資料集來源與連結
https://www.kaggle.com/datasets/mssmartypants/paris-housing-price-prediction
https://www.kaggle.com/datasets/larsen0966/student-performance-data-set
https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who

## 47 | Codex | 進度

我會依平均餘命報告的架構，為巴黎房價與學生成績補上實際計算、模型診斷及報告，並讓三個分頁各自連到正確的完整報告與 Kaggle 來源。

## 48 | Codex | 進度

我會使用 PDF 報告與網站預覽流程；新增報告會沿用原本的資料切分與模型，另外計算特徵選擇比較、殘差診斷及區間，並清楚標示結果的限制。

## 49 | Codex | 進度

兩份資料的統計與模型比較已算出。巴黎資料的 $R^2$ 非常接近 1，但它是虛構房價資料；學生成績模型則使用前兩期成績，報告會明確說明這兩項限制。

## 50 | Codex | 進度

兩份報告已產生，包含資料理解、模型比較、診斷與 95% 區間，也已完成版面檢查。接下來會把各報告與資料來源連結接到對應分頁，並確認切換後不會連錯檔案。

## 51｜Codex｜回覆

已為巴黎房價與學生成績完成統計分析和報告，並接到網站各自分頁的「閱讀完整報告」。三個分頁首頁也都明確顯示對應的 Kaggle 資料集名稱與連結。

**[開啟本機網站檢查](http://127.0.0.1:8000)**

兩份新報告均包含 CRISP-DM 六階段、資料統計、基準與特徵選擇比較、殘差診斷，以及 95% 信賴區間與預測區間。

巴黎房價報告：

:codex-file-citation{path="C:/Users/User/中興課程/01_物聯網/week7/hw_2/reports/paris_report.pdf" purpose="output"}

學生成績報告：

:codex-file-citation{path="C:/Users/User/中興課程/01_物聯網/week7/hw_2/reports/student_report.pdf" purpose="output"}

已確認三份 PDF 連結可正常開啟，14 項程式測試通過。報告仍需補上真實的 GPT 對話匯出與 NotebookLM 紀錄，並在繳交前核對教授最新規範。

## 52｜使用者

# Context from my IDE setup:

## Active file: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## Open tabs:
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
1.
資料集來源直接顯示 url 不太好看，請把平均餘命、巴黎房價跟學生成績的資料集來源修改成一個按鈕，按鈕餒加上文案顯示"資料來源 ↗"

2.請你把巴黎房價跟學生成績加上
研究總覽、分析流程、模型結果、預測體驗
按照平均餘命分頁的方式，點擊後，就可以把網頁滑動到該區塊

3.
請把圖片內的畫面移除，這跟要呈現的作業內容無關
[原始訊息附有圖片；此文字匯出未包含圖片。]

## 53｜Codex｜進度

我會把三個資料來源改成一致的按鈕，並讓每個分頁的導覽列滑到自己的內容區塊。您截圖中的六格介紹會移除，分析流程改為呈現各資料集實際使用的切分與建模方法。

## 54｜Codex｜進度

已移除截圖中的六格區塊；目前「分析流程」會顯示該資料集實際的資料切分、前處理與模型比較方式。我正在逐一檢查三個分頁的導覽與來源按鈕。

## 55 | Codex | 回覆

已完成調整：

- 三個資料集的來源網址改為「**資料來源 ↗**」按鈕。
- 巴黎房價與學生成績分頁加入四個導覽項目，點選後會滑到該分頁對應的區塊。
- 已移除截圖中的六格介紹，改以精簡文字呈現各資料集實際使用的分析方法。

已檢查分頁導覽與滑動，14 項程式測試通過。您可以在 [本機預覽](http://127.0.0.1:8000) 查看更新。

## 56 | 使用者

## My request:
1.
請你把巴黎房價跟學生成績的研究總覽、分析流程、模型結果、預測體驗文案的 UI 位置設計整體都往右一點
設計的跟平均餘命分頁的 UI 位置一樣

2.
把作業提交到以下 github 上，可以直接操作分頁
GitHub Repository: https://github.com/Ian1114/HW2-Multiple-Linear-regression

3.
並且用 github.io 的方式進行發布在網路上

## 57 | Codex | 進度

我會先對齊三個分頁的導覽位置，並檢查 GitHub 儲存庫及目前的發布方式。GitHub Pages 只提供靜態網頁，我也會確認預測功能在公開網站上能正常使用。

## 58 | Codex | 進度

目前專案還沒有連結到 Git 儲存庫，而 GitHub Pages 無法執行 Python 後端。我會保留本機後端，另準備可在靜態網站執行的預測版本，並核對公開版與原模型的結果。

## 59 | Codex | 進度

GitHub 儲存庫目前是公開且空的；我會建立不依賴 Python 伺服器的 Pages 版本，並保留分析程式與報告。公開版會包含您已要求顯示的姓名與學號。

## 60 | Codex | 進度

公開版已改成在瀏覽器內執行同一組線性模型，範例預測與原 Python 模型一致。接下來會檢查 GitHub Pages 版本的分頁、報告連結與預測功能，再提交到儲存庫。

## 61 | Codex | 進度

靜態版的三個資料集預測已接上模型，也已完成公開版的基本預覽。測試時發現臨時整理資料夾造成測試重複收集，我正在修正測試範圍後重新驗證。

## 62 | Codex | 進度

作業與靜態網站已推送到指定儲存庫。現在會設定 GitHub Pages 使用 `main` 分支的網站目錄，並確認公開網址與三個分頁是否正常。

## 63｜Codex｜進度

GitHub Pages 已設定為從‘main‘ 分支的‘docs‘ 目錄發布，GitHub 正在建置網站。我會等公開網址可用後，再檢查實際線上畫面與預測。

## 64｜Codex｜進度

GitHub 顯示網站部署成功。現在會直接開啟公開網址，確認不是只有本機版本可用。

## 65｜Codex｜回覆

已完成並發布：

- **[開啟作業網站](https://ian1114.github.io/HW2-Multiple-Linear-regression/)**
- [查看 GitHub 儲存庫](https://github.com/Ian1114/HW2-Multiple-Linear-regression)

巴黎房價與學生成績的導覽位置已調整得與平均餘命一致。GitHub Pages 部署成功，我也實際開啟公開網站，確認分頁與房價、成績的範例預測可以運作；15 項程式測試通過。

線上版在瀏覽器內使用匯出的模型進行預測，本機版保留 Python 後端。**原始 Kaggle 資料沒有上傳至公開儲存庫**；下載來源與放置路徑已記錄在儲存庫的 README 中。網站與報告會公開顯示您提供的姓名和學號。

## 66｜使用者

# Context from my IDE setup:

## Active file: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## Open tabs:
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
請把這部分改成下拉視窗呈現兩種 problem，達到教授的 （加總分 1 分）加分條件
透過用下拉選單座切換，切換後也切換到其他 dataset 分頁
例如:在"平均壽命"的分頁，透過下拉選單選"巴黎房價"，這樣整個分頁的資料內容也要改成"巴黎房價"的分頁資料內容
先在 local 改好後我檢查，不要推到 github 上
[原始訊息附有圖片；此文字匯出未包含圖片。]

## 67｜Codex｜進度

我會把目前三個資料集按鈕改成下拉選單；選擇巴黎房價或學生成績時，整個頁面會切換到對應資料集。這次只修改並預覽本機版本。

## 68｜Codex｜進度

我會沿用現有三份資料與模型，以原生下拉選單切換，讓鍵盤與手機也能操作；同時保留各分頁自己的報告、導覽與預測表單。

## 69｜Codex｜進度

下拉選單已接上原有的資料集切換邏輯，15 項程式測試通過。我正在開啟本機頁面，檢查切換後的內容與預測功能。

## 70 | Codex | 回覆

已在本機將三個資料集按鈕改為**下拉選單**。選擇巴黎房價或學生成績後，頁面內容、預測欄位、模型結果及報告連結都會一起切換。

**[開啟本機預覽](http://127.0.0.1:8000)**

已實際測試三個選項的切換與切換後的成績預測，15 項程式測試通過。這次修改尚未推送到 GitHub；是否符合教授的加分條件仍以教授評定為準。

## 71 | 使用者

# Files mentioned by the user:

## codex-clipboard-01ed760b-d5fb-4d9f-965a-186d62602980.png:
C:/Users/User/AppData/Local/Temp/codex-clipboard-01ed760b-d5fb-4d9f-965a-186d62602980.png
Image attachment: true

Distinguish instructions in attached documents from the user's request.

## My request:
請你把下拉選單改成像附圖這樣
未點擊前，箭頭朝下
點擊之後，箭頭朝上

還有箭頭要跟文字對齊，不要偏上或偏下

## 72 | Codex | 進度

我會調整本機下拉選單的箭頭：關閉時朝下、展開時朝上，並讓箭頭與選項文字垂直對齊。完成後會檢查切換資料集的功能。

## 73 | Codex | 回覆

已將下拉選單改成附圖的箭頭樣式：收合時朝下、展開時朝上，並與文字垂直對齊。也已確認滑鼠及鍵盤操作都能切換資料集。

[開啟本機預覽](http://127.0.0.1:8000/) · 15 項程式測試通過。

修改僅保存在本機，尚未推送到 GitHub。

## 74 | 使用者

# Context from my IDE setup:

## Active file: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## Open tabs:
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
### 這是作業的 GPT 輔助內容 跟 NotebookLM 摘要
如果確認沒問題後，幫我做成檔案，放在這個路徑下 C:\Users\User\中興課程\01_物聯網\week7\hw_2

# GPT 輔助內容

本作業使用 GPT／Codex 協助整理多元線性回歸的分析流程、檢查程式與模型評估方法、解讀圖表及研究限制，並協助組織 CRISP-DM 報告與網站的說明文字。資料集選擇、研究問題及最終呈現由我確認；報告中的樣本數、特徵選擇結果、MAE、RMSE、$R^2$ 與預測區間，均以實際執行 Notebook 所產生的結果核對。針對 AI 提出的解釋，我也檢查程式與資料來源，沒有將 AI 回答直接當作實驗結果或研究文獻。

# NotebookLM 摘要

我使用 NotebookLM 研究 Furkan Kazan 在 Kaggle 發表的 WHO 平均餘命線性回歸 Notebook，並與本作業比較。兩者都使用 WHO 平均餘命資料建立線性回歸模型，但處理缺值與評估模型的方式不同。Kaggle Notebook 刪除部分有缺值的資料列，並採用隨機資料列切分；本作業只刪除缺少預測目標的 10 筆紀錄，其餘特徵在訓練流程中補值，並依國家分組，以未參與訓練的國家進行評估。本作業也比較完整模型與兩種特徵選擇方法。

比較時，我發現 Kaggle Notebook 的線性模型在切分測試集之前，已使用全部資料訓練，因此其後顯示的 $R^2$ 不能視為獨立測試結果。兩份研究雖然都報告 $R^2$，仍不能直接以數值高低判斷模型優劣；若要公平比較，必須使用相同的資料處理、特徵及測試方式。這次研究讓我了解，解讀模型結果時，評估流程與分數同樣重要。

研究來源：[Furkan Kazan 的 Kaggle Notebook](https://www.kaggle.com/code/furkankazan/life-expectancy-linearregression)；[本作業報告](https://ian1114.github.io/HW2-Multiple-Linear-regression/report.pdf)。

## 75｜Codex｜進度

我會先核對摘要中對 Kaggle Notebook 與本作業流程的描述，再整理成可放在作業資料夾的檔案；若有無法從來源確認的說法，我會明確標出。

## 76｜Codex｜進度

已核對 Kaggle Notebook 的第 19–22、48–52 格：它刪除部分缺值列、以 GDP 中位數補值，並在切分前訓練線性模型；之後的線性模型測試分數確實不是獨立測試結果。NotebookLM 的實際使用過程則只能由您的紀錄佐證。

## 77｜Codex｜回覆

已核對並整理成檔案：

[5115056026_GPT輔助與NotebookLM摘要.md](C:/Users/User/中興課程/01_物聯網/week7/hw_2/5115056026_GPT輔助與NotebookLM摘要.md)

內容做了兩處精確化：補上 Kaggle Notebook 以中位數填補 GDP 缺值，並將結果來源改為「Notebook 或分析程式」，因為巴黎房價與學生成績的分析也使用了 Python 程式。

Kaggle Notebook 的程式順序已核對；**NotebookLM 的實際使用過程仍需由您的紀錄佐證**。此摘要也不能取代教授要求的 GPT 對話 PDF。

## 78｜使用者

# Context from my IDE setup:

## Active file: 5115056026_GPT輔助與NotebookLM摘要.md

## Open tabs:
- 5115056026_GPT輔助與NotebookLM摘要.md: 5115056026_GPT輔助與NotebookLM摘要.md
- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
請你按照教授的的加分條件，設計出"可任意輸入 Dataset"的功能，達到教授的 （加總分 2 分）加分條件

先在 local 改好後我檢查，不要推到 github 上

## 79｜Codex｜進度

我會在本機網站加入自訂資料集功能：上傳 CSV 後選擇預測目標與輸入特徵，執行多元線性回歸並顯示測試結果。會先檢查既有架構及教授條件，完成後只在本機供您檢查。

## 80｜Codex｜進度

我會使用測試驅動開發，先確認自訂資料集的欄位檢查與模型評估，再接上現有網站的選單。這項功能會保留原本三個資料集，且只在本機運作。

## 81｜Codex｜進度

資料集檢查與回歸計算已完成初步驗證：可辨識數值與類別欄位，並以獨立測試集評估。接下來會把上傳、欄位選擇和結果畫面整合到現有的資料集下拉選單。

## 82｜Codex｜進度

自訂資料集頁面已接上：上傳後可選擇目標與特徵，並查看訓練集、測試集和交叉驗證結果。目前既有測試及新功能測試均已通過；我正在啟動本機網站檢查實際操作。

## 83｜Codex｜進度

我會使用電腦操作工具開啟本機網站，確認選單切換及頁面呈現。

## 84｜Codex｜進度

本機頁面已能切換到「自訂資料集」。我也補上逗號、分號及 Tab 分隔格式的支援，接著會用實際資料檢查上傳後的分析結果。

## 85｜Codex｜回覆

已在本機新增「**04 自訂資料集**」頁面，並開啟在 [本機網站](http://127.0.0.1:8000/) 供您檢查。這次沒有推送到 GitHub。

您可以上傳 UTF-8 CSV，選擇數值預測目標及至少兩個輸入特徵，再執行多元線性回歸。結果會顯示訓練集與測試集的 MAE、MSE、RMSE、$R^2$，以及五折交叉驗證和平均值基準結果。頁面也會提示特徵數量與資料洩漏的注意事項。

目前支援最多 8 MB 的 CSV，並可辨識逗號、分號或 Tab 分隔。已用巴黎房價與學生成績資料測試分析計算，所有 19 項自動測試通過；瀏覽器中的選單與頁面切換也已檢查。**瀏覽器上傳操作本身尚未完成端到端驗證**，您可以在目前開啟的頁面選擇檔案試用。

功能已依您描述的加分方向實作；是否符合教授完整的加分認定，仍需由教授評分確認。

## 86｜使用者

# Context from my IDE setup:

## Active file: 5115056026_GPT輔助與NotebookLM摘要.md

## Open tabs:
- 5115056026_GPT輔助與NotebookLM摘要.md: 5115056026_GPT輔助與NotebookLM摘要.md

- 2026-10-19-hw2-regression-design.md: docs/superpowers/specs/2026-10-19-hw2-regression-design.md

## My request:
1.請你新增一按鈕，讓作業可以分析 dataset
目前只有上傳的功能，但是不能分析，這樣是錯的

2.新增一個叉叉的 icon，讓 user 可以在網頁上移除 dataset 檔案
[原始訊息附有圖片；此文字匯出未包含圖片。]

## 87｜Codex｜進度

我會先找出上傳後無法分析的原因，修正流程，並加入明顯的「分析資料集」按鈕與移除檔案的叉叉。完成後會在本機實際操作驗證，不推送到 GitHub。

## 88｜Codex｜進度

我會使用系統化除錯與測試驅動開發檢查這個問題。初步發現原本的分析按鈕藏在檔案解析成功後才會顯示，尚未選檔或解析失敗時看不到，因此會調整成一眼可見的操作流程。

## 89｜Codex｜進度

已確認兩個原因：分析按鈕原本要等解析成功才出現；另外，像平均餘命資料中的國家欄位有超過 100 種類別，原本預設全選會使訓練失敗。我已讓按鈕固定顯示，並預設排除這類無法直接處理的欄位；現在正檢查完整操作。

## 90｜Codex｜進度

按鈕與移除功能已加入，原本的測試也全數通過。我正在做最後的瀏覽器驗證，特別確認選檔、開始分析與移除後重新選檔的狀態。

## 91｜Codex｜回覆

已在本機加入「**分析資料集**」按鈕，以及選檔後出現的「**x**」移除按鈕。您可以在已開啟的［本機頁面］(http://127.0.0.1:8000/) 的「自訂資料集」分頁查看；尚未選檔時，分析按鈕會暫時停用。

選擇 CSV 後，請確認預測目標與輸入特徵，再按「分析資料集」查看結果。按「x」會清除網頁目前選取的檔案和分析結果，電腦上的原始檔案不會被刪除。

我已用三份作業資料集驗證分析計算，20 項自動測試也已通過。不過，這次自動化工具未能完成瀏覽器選檔，因此**上傳、分析到移除的完整網頁操作仍需要您在本機試用確認**。變更尚未推送到 GitHub。

## 92｜使用者

## My request:
###請把以下資訊依照作業要求併入公開 PDF
1. NotebookLM 研究同主題解法、100 字以上摘要放入報告
2. 報告標示「GPT 輔助內容」與「NotebookLM 摘要」

###另外把本次跟 ChatGPT 對話匯出 PDF
也一併放在這個路徑下 C:\Users\User\中興課程\01_物聯網\week7\hw_2

###確認都有按照老師對作業的規則後，直接推上 GITHUB

## 93｜Codex｜進度

我會先核對老師的作業規範、現有公開報告及您整理的 GPT／NotebookLM 內容，再更新 PDF 並確認網站引用的版本。也會檢查能否完整匯出本次對話，完成驗證後直接推送 GitHub。

## 94｜Codex｜進度

我會使用 PDF 工作流程處理報告，並核對公開版本與原始報告是否一致。作業規範另外要求保留 GPT 對話與 NotebookLM 實際使用紀錄，我也會檢查目前能取得哪些原始紀錄。

## 95｜Codex｜進度

已核對到作業要求：報告需明確標示兩項 AI 使用內容，NotebookLM 摘要至少 100 字，另附對話 PDF。現有公開報告仍保留「待補入 AI 使用證據」的草稿文字，我會直接更新報告來源與公開 PDF；對話檔只放在您指定的本機資料夾。

## 96｜Codex｜進度

報告已加入兩個指定標題與超過 100 字的 NotebookLM 摘要，並保留研究來源及評估方式比較。對話 PDF 也已產生；我正在檢查頁面、內容完整性，以及公開網站會使用的 PDF。

## 97｜Codex｜進度

PDF 已完成版面檢查，公開報告與網站使用的版本內容一致。我也依老師的繳交格式，另外整理了本機 ZIP，將分析報告與對話紀錄合併成一份完整報告；私人對話不會放進公開網站。

## 98｜Codex｜進度

本機完整報告與繳交 ZIP 已通過檔案完整性檢查。Git 提交時發現此環境沒有設定作者資訊；我會沿用此儲存庫上一筆提交使用的 GitHub 名稱與匿名信箱，繼續發布報告。

## 99｜Codex｜進度

報告更新已推送到 GitHub，GitHub Pages 正在執行發布流程。我會確認部署結果後再提供公開連結與本機檔案。

## 100｜Codex｜回覆

已將「GPT 輔助內容」與超過 100 字的「NotebookLM 摘要」加入報告，並推送到 GitHub。GitHub Pages 部署已成功完成。

- [線上公開報告](https://ian1114.github.io/HW2-Multiple-Linear-regression/report.pdf)
- [本機 GPT／Codex 對話紀錄 PDF](<C:/Users/User/中興課程/01_物聯網/week7/hw_2/5115056026_GPT對話紀錄.pdf>)
- [本機完整報告 PDF](<C:/Users/User/中興課程/01_物聯網/week7/hw_2/5115056026_hw2_完整報告.pdf>)：包含分析報告與對話紀錄
- [本機作業 ZIP](<C:/Users/User/中興課程/01_物聯網/week7/hw_2/5115056026_hw2.zip>)：包含改名後的 Notebook、報告、對話及相關資料

已對照現有的老師作業規範，檢查 CRISP-DM、特徵選擇、模型評估、區間圖及指定 AI 內容；20 項自動測試與 ZIP 完整性檢查均通過。

有兩點請您提交前確認：對話 PDF 包含可取得的文字對話，但**未收錄原始圖片或工具執行細節**；NotebookLM 摘要依您提供的內容整理，我無法獨立核對 NotebookLM 的實際使用紀錄。

這次公開的是報告更新；先前要求先在本機檢查的**自訂資料集功能仍保留在本機**，尚未併入公開網站。

## 101｜使用者

## My request:

1.

請你把 hw_2 整包程式碼也一併推上 GITHUB

你原先少推了

2.

重新匯出 GPT 堆話紀錄 PDF

然後把 hw2_完整報告 pdf 跟 GPT 堆話紀錄 PDF 也一起推上 GITHUB

3.

最後檢查 https://ian1114.github.io/HW2-Multiple-Linear-regression/ 是不是跟我本機的前端畫面的功能都一樣

## 102｜Codex｜進度

我會先比對本機與 GitHub 的程式和功能差異，重新匯出對話 PDF，再把完整報告及可公開的專案檔案推上儲存庫。最後會實際檢查 GitHub Pages；若靜態網站無法直接支援本機後端功能，我會一併處理或明確說明限制。

## 103｜Codex｜進度

我會使用 PDF 工作流程重新匯出對話，並以系統化檢查比對兩個版本。已確認主要差異是自訂 CSV 分析目前仰賴本機 Python 後端，而 GitHub Pages 是靜態網站；我正在評估讓線上版也能執行分析的方式。

## 104｜Codex｜進度

我會使用網站與測試驅動開發流程處理差異：讓公開版在瀏覽器內執行與本機相同的 Python 分析，這樣 CSV 不必送到外部伺服器。首次使用需要下載分析套件，載入時間可能較長。

## 105｜Codex｜進度

公開版的四個資料集選單與自訂分析頁面已接上；我正在用測試 CSV 走完整個選檔、分析和移除流程。首次載入瀏覽器分析環境需要一些時間。