WHO 平均餘命：多元線性回歸分析

CRISP-DM 作業報告｜資料與程式執行日期：2026-11-01｜姓名：李易軒｜學號：5115056026

摘要

以國家年度健康與社經指標估計平均餘命。原始檔有 2,938 筆；排除 10 筆缺少目標後，依國家切分訓練與保留資料。以訓練國家的五折交叉驗證選擇 OLS 主模型；20 特徵 OLS 的保留集 MAE 為 3.121 年、RMSE 為 4.063 年，R^2 為 0.823。資料中的同年度死亡率等欄位可能與目標存在概念重疊，本研究不能解讀為因果效果或未來預測。

1. Business Understanding｜問題理解

研究問題：能否利用國家年度的健康與社經資訊估計未見國家的平均餘命？成功標準為優於訓練資料平均值基準，並檢查誤差、特徵選擇與線性模型限制。此資料為國家層級觀測，不能推論個人壽命。

2. Data Understanding｜資料理解

資料來源：Kaggle「Life Expectancy (WHO)」：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who 。本機 CSV 包含 193 國、2000–2015 年、22 欄；國家及年份組合沒有重複。目標為 Life expectancy；20 個輸入包含 Year、Status 與 18 個健康、人口及社經數值指標。原始 CSV 的 SHA-256：872125dd1dd0f9140fbead61df20585a815f5cf47db68f08bf54efaf87963b11。

缺失較多的欄位包括 Population（652）、Hepatitis B（553）及 GDP（448）；目標缺失 10 筆直接排除。資料來源描述、版本與再散布條件須於提交前核對。

3. Data Preparation | 資料準備

國家名稱不進模型，只作分組依據。Status 以 Developing=0、Developed=1 編碼。保留 37 個國家共 592 筆，其餘 146 個國家共 2,336 筆訓練；資料分組以 seed 42 固定。訓練集內使用五折 GroupKFold，同一國家不會跨訓練折與驗證折。中位數補值與標準化放入 pipeline，由各折訓練資料擬合。此切分評估跨國泛化，並不驗證對未來年份的預測。

4. Modeling | 建模

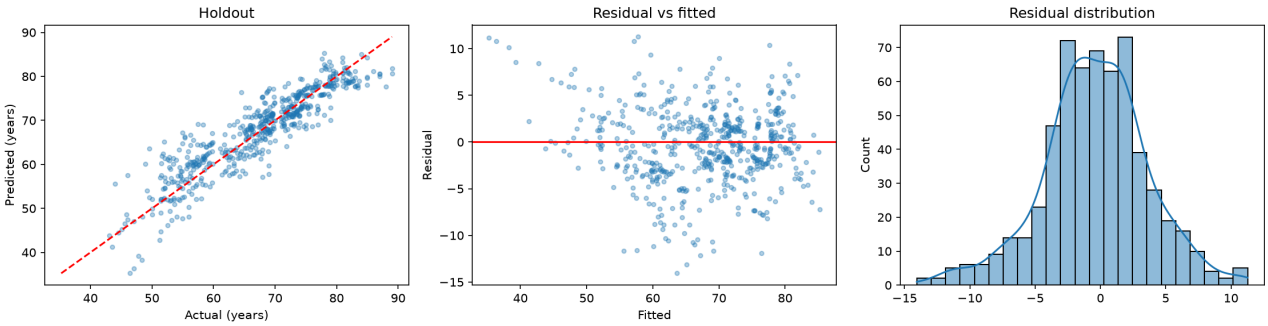
候選包括平均值基準、20 特徵 OLS、SelectKBest 與 RFE 各選 14 特徵，以及 Ridge、Lasso；正則化強度以相同分組交叉驗證比較。以訓練 CV RMSE 選 OLS 主模型，結果為全部 20 特徵；CV 選參後的最佳分數可能樂觀，保留集用作最終評估。

模型	CV RMSE	保留集 MAE	保留集 RMSE	保留集 R^2
dummy	9.434	7.982	9.949	-0.059
ols	4.337	3.121	4.063	0.823
kbest	4.635	3.122	4.122	0.818
rfe	4.338	3.121	4.063	0.823
ridge_1	4.270	3.116	4.059	0.824
lasso_0.01	4.284	3.110	4.057	0.824

OLS、RFE 的 CV RMSE 幾乎相同，兩者的差距不應被解讀為明確的實務優勢。選取清單儲存在 outputs/selected_features.json；Lasso 最終保留 19 個非零係數，屬補充比較。

5. Evaluation | 評估

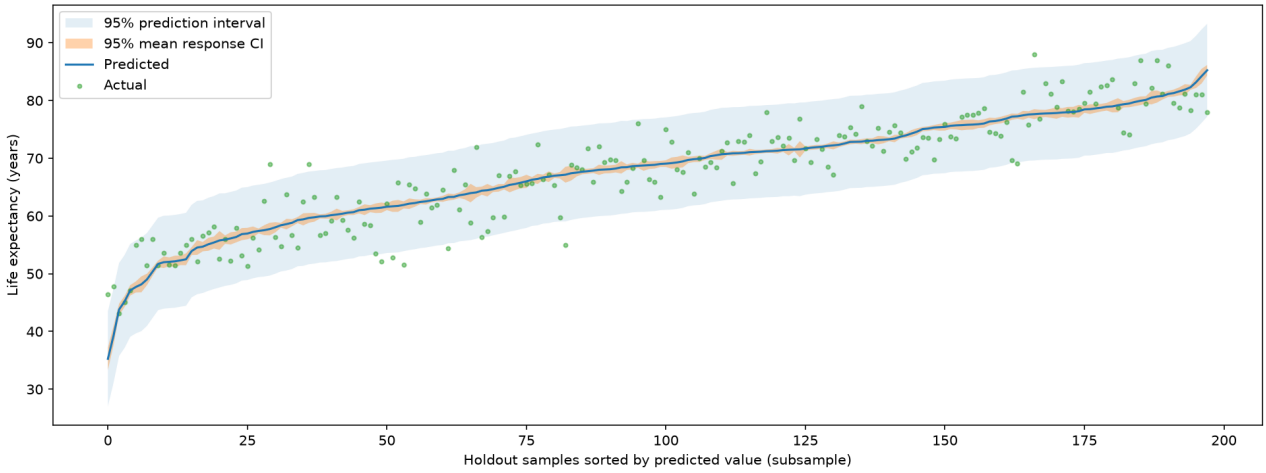
保留集的 OLS 調整後 R^2 為 0.817；平均值基準 RMSE 為 9.949 年。實際值與預測值及殘差圖如下。不同國家、年度的資料量不一，這些指標按資料列計算，不是每國等權的平均誤差。



回歸診斷與區間

訓練資料 Breusch－Pagan LM 檢定 p 值約
3.88e-58，提示殘差變異可能不一致；同國觀測相依使傳統檢定的推論受到限制。infant deaths 與 under-five deaths 的 VIF 約為 189 與 188，顯示嚴重共線性。殘差圖與 Q-Q
圖可協助判斷線性及常態偏離；同國跨年度相依性不能從任意排序的 Durbin－Watson 判定。

以下是依預測值排序的部分保留樣本，帶狀區分 95% 平均反應信賴區間與單筆觀測預測區間。區間依傳統 OLS 假設計算，未納入模型選擇的不確定性；異質變異與國家內相關可能使覆蓋率偏離 95%。



6. Deployment｜部署

完整前處理與選定的 OLS 已存為 joblib；Notebook 驗證重載前後預測一致。可使用 hw2lib.predict 接收新 CSV，檢查必要欄位、數值與 Status
類別，再輸出預測。此研究模型不應直接用於政策或個人判斷。

限制與後續

這是觀察性、國家層級、歷史資料；不可宣稱因果。資料可能存在指標定義變更、缺失機制不隨機、估計值誤差及同國年度相依。部分死亡率與平均餘命在概念或推估流程可能重疊，需確認發布時間與來源後才能主張事前預測。OLS 係數受嚴重共線性影響，係數方向及大小不能直接解讀為政策效果。

GPT 輔助內容

本作業使用 GPT／Codex
協助整理多元線性回歸的分析流程、檢查程式與模型評估方法、解讀圖表及研究限制，並協助組織 CRISP-DM 報告與網站的說明文字。資料集選擇、研究問題及最終呈現由我確認；報告中的樣本數、特徵選擇結果、MAE、RMSE、R^2 與預測區間，均以實際執行 Notebook 或分析程式所產生的結果核對。針對 AI 提出的解釋，我也檢查程式與資料來源，沒有將 AI 回答直接當作實驗結果或研究文獻。

NotebookLM 摘要

我使用 NotebookLM 研究 Furkan Kazan 在 Kaggle 發表的 WHO 平均餘命線性回歸 Notebook，並與本作業比較。兩者都使用 WHO 平均餘命資料建立線性回歸模型，但處理缺值與評估模型的方式不同。Kaggle Notebook 刪除部分有缺值的資料列，以中位數補入 GDP 的缺值，並採用隨機資料列切分；本作業的平均餘命分析只刪除缺少預測目標的 10 筆紀錄，其餘特徵在訓練流程中補值，並依國家分組，以未參與訓練的國家進行評估。本作業也比較完整模型與兩種特徵選擇方法。

比較時，我發現 Kaggle Notebook 的線性模型在切分測試集之前，已使用全部資料訓練，因此其後顯示的線性回歸 R^2 不能視為獨立測試結果。兩份研究雖然都報告 R^2，仍不能直接以數值高低判斷模型優劣；若要公平比較，必須使用相同的資料處理、特徵及測試方式。這次研究讓我了解，解讀模型結果時，評估流程與分數同樣重要。

研究來源：Furkan Kazan，Life_Expectancy_LinearRegression，版本 6，程式第 19–22、48–52 格。Kaggle Notebook 原文 ↗。NotebookLM 的使用描述與摘要依作業者提供之紀錄整理；對話紀錄另存 PDF。