學生成績：多元線性回歸分析

CRISP-DM 作業報告草稿｜姓名：李易軒｜學號：5115056026｜分析日期：2026-11-01

摘要

以 20 個原始輸入特徵估計 G3，使用固定種子切分及訓練集內五折交叉驗證。完整 OLS 在保留測試集的 MAE 為 0.726、MSE 為 1.334、RMSE 為 1.155、R^2 為 0.86320061。單位：分（0–20）。

1. Business Understanding｜問題理解

使用學生背景、學習資訊與第一、二期成績，估計葡萄牙語課程最終成績 G3，並比較平均值基準及特徵選擇版本。

2. Data Understanding｜資料理解

本研究使用指定 Kaggle 下載的 student-por.csv：葡萄牙語課程資料。原始檔 33 欄，研究依既定網站模型選用 20 個輸入欄位，目標 G3 不計入特徵。

原始檔共 649 筆、33 欄；全表缺失值 0 個，目標缺失 0 筆，完全重複列 0 筆。目標欄位為 G3。

資料集來源：https://www.kaggle.com/datasets/larsen0966/student-performance-data-set

本機原始檔 SHA-256：5be7b02f13f5800fddd66e2c8d834cd00ece14c552fb404def2397b31b63236b

3. Data Preparation｜資料準備

使用 random_state=42 隨機切分為訓練 519 筆及保留測試 130 筆。數值欄位採中位數補值與標準化；類別欄位以訓練資料眾數補值及獨熱編碼。上述步驟、特徵選擇與模型都在 pipeline 內，訓練集以打亂的五折交叉驗證擬合，避免驗證折資訊洩漏。

完整模型輸入：sex, age, address, Medu, Fedu, traveltime, studytime, failures, schoolsup, famsup, paid, activities, higher, internet, famrel, goout, health, absences, G1, G2。

4. Modeling｜建模與特徵選擇

比較平均值基準、完整 OLS，以及 SelectKBest 和 RFE 各 14 特徵版本。完整 OLS 是原網站已部署的模型；額外比較不根據保留測試集更改已使用的網站模型。CV 指標為五折平均，標準差為各折的標準差。

模型	CV RMSE ± SD	訓練 RMSE	測試 RMSE	測試 R^2
dummy	3.233 ± 0.391	3.244	3.173	-0.03215980
OLS all	1.300 ± 0.268	1.257	1.155	0.86320061
KBest 14	1.290 ± 0.272	1.267	1.143	0.86604739
RFE 14	1.301 ± 0.266	1.259	1.163	0.86119665

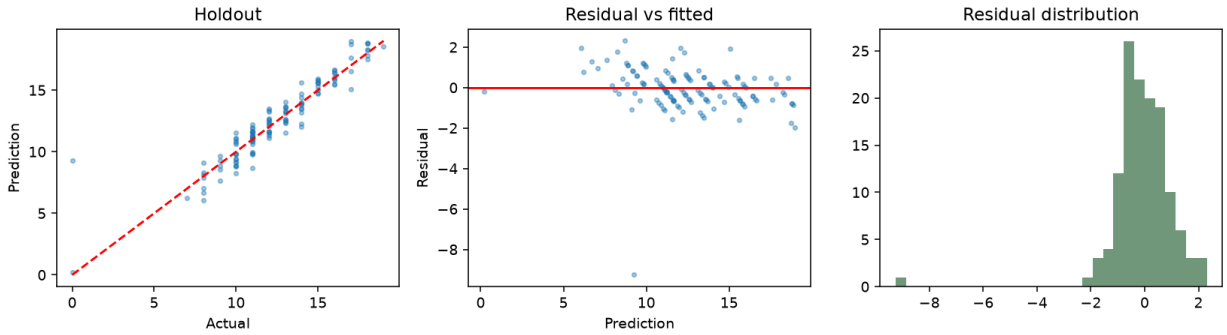
KBest 在訓練折中依單變數關聯選 14 欄，RFE 在訓練折中遞迴移除特徵。資料中此處類別皆為二元，獨熱編碼各產生一個欄位；選取數對應 14 個原始特徵。

SelectKBest 14 欄：age, Medu, Fedu, traveltime, studytime, failures, goout, health, G1, G2, sex_M, address_U, higher_yes, internet_yes。

RFE 14 欄：Medu, traveltime, studytime, failures, famrel, absences, G1, G2, sex_M, address_U, schoolsup_yes, famsup_yes, paid_yes, internet_yes。

5. Evaluation｜評估

完整 OLS 訓練 RMSE 為 1.257；五折 CV RMSE 為 1.300 ± 0.268；保留測試 RMSE 為 1.155。測試集調整後 R^2 為 0.83809980（n=130，p=20）。

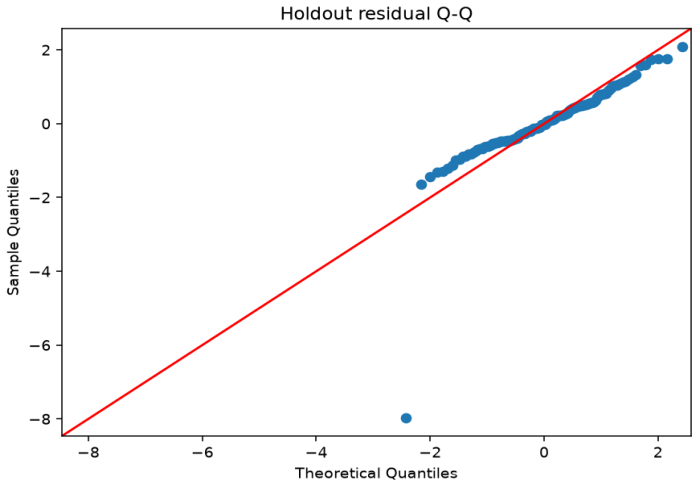


左圖比較實際與預測，虛線為理想位置；中圖檢視殘差與預測值；右圖為測試殘差分布。

回歸假設與診斷

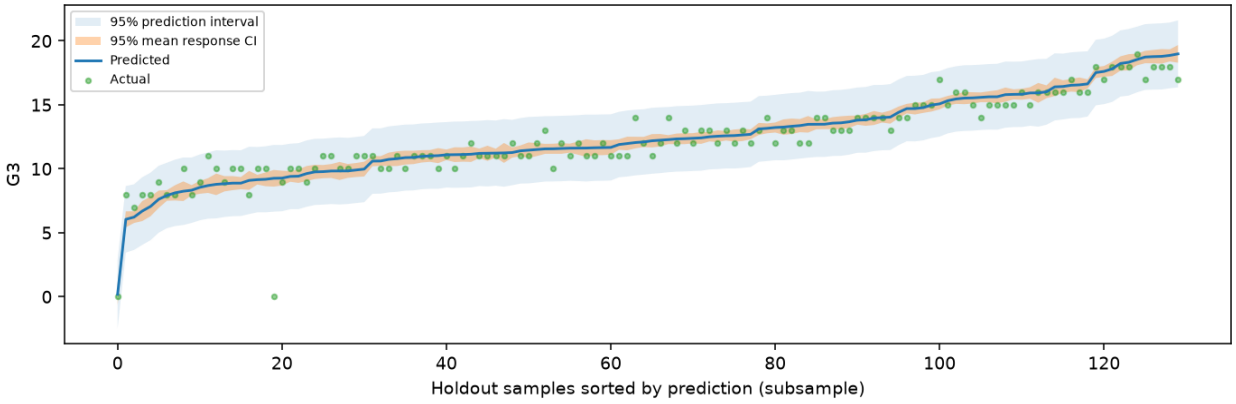
訓練集 Breusch－Pagan 檢定 LM=38.999，p=6.669e-03，顯示常態參考下可能存在異質變異。最大 VIF 為 4.069（G1）；VIF 衡量線性共線性，不能單獨證明其他假設成立。設計矩陣 rank=21，欄數（含截距）=21。

線性與等變異可從殘差圖觀察；常態性可參考下方 Q-Q 圖。獨立性取決於抽樣與資料產生方式，任意檔案排序下的 Durbin－Watson 不能證明獨立。資料集的抽樣與生成限制應納入判斷。



95% 信賴與預測區間

以下按預測值排序並抽樣顯示保留集：窄帶為平均反應信賴區間，寬帶為單筆觀測預測區間。statsmodels 與網站 OLS 的點預測已核對一致。傳統區間依 OLS 假設計算，未納入特徵選擇不確定性；異質變異或資料相依可能使涵蓋率偏離 95%。



6. Deployment｜部署

本機表單輸入 20 個原始欄位，後端讀取原有完整 OLS 管線回傳預測。

模型與前處理一起保存；展示系統不儲存輸入。請確認訓練來源與模型版本一致，本地展示不代表已公開部署。

限制與後續

G1、G2 已包含前期成績，模型只適合已取得這些成績的情境，不是入學前預測。分數與社會人口資料屬觀察關係，不能作因果或單獨教育決策；線性預測可能超出 0–20，未靜默裁切。隨機切分不保證跨學校或跨時間泛化。

測試結果只適用於此固定切分；要評估結果穩定性，應另行研究重複切分或適合資料取得方式的外部驗證。OLS 的相關性不代表因果。

參考資料

資料集：https://www.kaggle.com/datasets/larsen0966/student-performance-data-set

scikit-learn：線性模型與交叉驗證文件 https://scikit-learn.org/stable/modules/linear_model.html ；https://scikit-learn.org/stable/modules/cross_validation.html

statsmodels：OLS 預測區間 https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLSResults.get_prediction.html

AI 使用與待補項目

Codex 協助程式、分析與報告整理。真實對話 PDF 與實際 NotebookLM 研究紀錄、至少 100 字摘要仍須由使用者補充；不可將此段冒充 NotebookLM 產出。提交前請核對教授最新規範與資料授權。